



Bull- och bear-marknader i S&P 500

- Hur kan dolda Markovmodeller identifiera bull- och bear-marknader i S&P 500?

Författare: Loran Ali och Viktor Emilsson

Handledare: Tamás Kiss

Examinator: Niklas Karlsson

Sammanfattning (abstract)

Syftet med denna studie är att undersöka hur väl en Gaussisk Dold Markovmodell (GHMM) kan identifiera bull- och bear-marknader i S&P 500, samt analysera hur modellernas prestanda påverkas av variabler och antalet latent tillstånd. Studien baseras på daglig data för S&P 500 hämtad från Yahoo Finance för perioden 2000-2025. Marknadsregimerna definieras genom LT-algoritmen introducerad av Lunde och Timmermann (2004).

Fyra modellvarianter estimeras och jämförs: två modeller baserade enbart på genomsnittlig avkastning med två respektive tre tillstånd, samt två modeller som även inkluderar volatilitet och handelsvolym som variabler med två respektive tre tillstånd. Modellerna utvärderas med hjälp av måtten accuracy, precision, recall, F1-score, coverage samt informationskriterierna AIC och BIC.

Resultaten visar att GHMM uppvisar god förmåga att identifiera marknadsregimer i S&P 500. De utökade modellerna, vilka inkluderar volatilitet och handelsvolym, bidrar till en förbättrad förmåga att identifiera nedgångsperioder, medan införandet av ett tredje latent tillstånd möjliggör en mer djupgående förståelse av marknadsdynamiken. Modellen med tre tillstånd, där enbart genomsnittlig avkastning inkluderades som variabel, uppvisade den bästa statistiska anpassningen enligt AIC och BIC. Samtidigt framstod modellen med två tillstånd, som utöver genomsnittlig avkastning även inkluderade volatilitet och volym, som den mest ändamålsenligt för att identifiera marknadsnedgångar.

Sammantaget visar resultaten att GHMM utgör en statistiskt användbar modell för identifiering av marknadsregimer, där modellernas egenskaper påverkas av variabeluppsättning och antalet latent tillstånd.

Nyckelord: GHMM, S&P 500, bull-marknad, bear-marknad, regimidentifiering, maskininlärning

1. Inledning	1
1.1 Syfte och frågeställningar	2
1.2 Disposition	2
2. Bakgrund och tidigare studier	3
3. Metod och modell	5
3.1 Datadefinition	5
3.2 Observationsekvation och parameterestimering.....	5
3.3 Latenta tillstånd	6
3.4 Markov-egenskap och övergångssannolikhet	6
3.5 Inferens (Filtrering)	7
3.6 Definitioner av marknadsregimer	7
3.7 AIC och BIC	8
3.8 Mått och utvärdering.....	9
4. Data	10
4.1 Datakälla	10
4.2 Datagranskning.....	11
4.3 Etikettering	11
4.3.1 Algoritmen	12
4.4 Klassfördelning	12
4.5 Variabler	13
4.6 Datarensning och begränsningar	14
5. Resultat och analys	15
5.1 Konvergens	15
5.2 Tillståndsmappning	16
5.3 Prestanda.....	19
5.4 Skattade Gaussiska parametrar.....	21
5.5 Övergångsmatris	23
5.6 AIC och BIC	25
5.7 Sammanfattning.....	26
6. Diskussion och slutsatser	27

Appendix/Bilagor	31
-------------------------------	-----------

1. Inledning

Investeringar utgör en central del av många individers ekonomiska beslut, där förmågan att placera kapital på ett effektivt sätt ofta innebär en betydande utmaning. S&P 500 är ett av världens mest betydelsefulla aktieindex och används ofta som en indikator för den globala marknadsutvecklingen.

I detta sammanhang spelar begreppen bull- och bear-marknader en central roll vid analys av mönster i finansiella marknader. I denna studie används den klassificeringsmetoden som (Lunde & Timmermann, 2004) introducerade. Där en bear-marknad identifieras när priset fallit med minst 10 procent från sin senaste topp, medan en bull-marknad föreligger när priset stigit med minst 15 procent från sin senaste botten. Att trösklarna är asymmetriska motiveras av att aktiemarknader historiskt uppvisat olika dynamik i upp- och nedgångsperioder. I vidare mening tenderar återhämtningsfaser att utvecklas mer successivt, medan nedgångsperioder karaktäriseras av kraftigare rörelser i pris och högre volatilitet. Att identifiera vilken av dessa två regimer marknaden befinner sig i är betydande för portföljförvaltning, riskhantering och strategiska allokeringsbeslut.

Samtidigt kan det observeras att finansiella marknader karaktäriseras av hög volatilitet, icke-linjära mönster och strukturella skiften, vilket gör att traditionella prognosmodeller ofta har svårt att fånga dynamiken i övergångar mellan bull- och bear-marknader. På senare år har därför statistiska tidsseriemodeller för regimidentifiering fått en allt mer central roll i den finansiella forskningen. En av de mest etablerade metoderna är dolda Markovmodeller, som länge använts för att modellera icke-observerbara tillstånd i tidsserier och som är särskilt lämpade för problem där de underliggande regimerna inte är direkt mätbara. Genom att utgå från observerbara variabler som daglig avkastning, volatilitet och handelsvolym kan modellen estimeras sannolikheten för att marknaden vid en given tidpunkt befinner sig i ett bull- eller bear-tillstånd, samt skatta hur ofta och under vilka förutsättningar regimskiften inträffar. Detta gör Markovmodeller till ett naturligt och datadrivet verktyg för att studera bull- och bear-marknader på aktiemarknaden, vilket också utgör utgångspunkten för denna uppsats.

1.1 Syfte och frågeställningar

Syftet med denna uppsats är att undersöka i vilken utsträckning en Gaussisk Dold Markovmodell (GHMM) kan identifiera och förutsäga bull- och bear-marknader i S&P 500, samt att analysera hur modellens prestanda påverkas av valet av variabler och antalet latent tillstånd. För att uppfylla syftet besvaras följande frågeställningar:

1. Hur väl kan en Gaussisk Dold Markovmodell baserat på daglig avkastning identifiera bull- och bear-marknader i S&P 500?
2. Hur påverkas modellens prestanda av att utöka variablerna från enbart daglig avkastning till en utökad uppsättning som även inkluderar volatilitet och handelsvolym?
3. Hur påverkas modellens prestanda och tolkning av att utöka antalet latent tillstånd från två (bull och bear) till tre (bull, bear och neutral)?

1.2 Disposition

I avsnitt 2 presenteras tidigare forskning och studier som är relevanta för vår studie. Därefter redogörs för den metodologiska ansatsen och de metoder som tillämpas i avsnitt 3. I avsnitt 4 beskrivs det datamaterial som ligger till grund för analysen. Vidare presenteras och analyseras studiens resultat i avsnitt 5. Slutligen sammanfattas arbetets huvudsakliga resultat och slutsatser i avsnitt 6, där även en avslutande diskussion förs. Referenser återfinns i avsnitt 7.

2. Bakgrund och tidigare studier

Forskning om marknadstrender, såsom bull- och bear-marknader, har länge varit av stort intresse. Att förstå hur marknaden fungerar och hur investeringar kan optimeras är något som alltid är relevant. Samtidigt finns det många faktorer och omständigheter som gör detta komplext och utmanande.

Haase och Neuenkirch (2023) undersöker möjligheten att förutsäga bull- och bear-marknader i S&P 500 genom att hantera utmaningar kopplade till modellosäkerhet och ett stort antal förklarande variabler. Studien bygger på en trestegsmetod där högdimensionell makroekonomisk och finansiell data först reduceras med hjälp av Principalkomponentanalys (PCA). Därefter används Markovmodeller för att modellera sannolikheten för övergångar mellan latenta marknadsregimer. I ett tredje steg kombineras prognoser från flera modeller genom så kallad forecast combination, med syfte att öka robustheten i resultatet.

Resultaten visar att modellerna har förmåga att identifiera regimskiften och kan bidra till att förbättra riskjusterad avkastning, särskilt under perioder av marknadsnedgångar. Parallellt framkommer att de mer komplexa modellerna inte konsekvent överträffar enklare referensmodeller när det gäller att prognostisera avkastningar. Studien antyder därmed att det är lättare att identifiera marknadens riktning, i termer av bull- eller bear-regimer, än att exakt prognostisera framtida avkastningsnivåer.

Vidare analyserar Lunde och Timmermann (2004) varaktigheten av bull- och bear-marknader, med syftet att undersöka hur länge dessa regimer består. Studien använder sig av en så kallad hazard rate-modell för att estimerar sannolikheten att en pågående marknadsregim avslutas vid en given tidpunkt. Till skillnad från Haase och Neuenkirch (2023), som fokuserar på att förutsäga regimskiften, ligger fokus här i stället på att analysera regimernas varaktighet.

Resultaten visar att bull-marknader uppvisar en förhöjd grad av stabilitet över tid, där sannolikheten att en bull-regim avslutas minskar ju längre den har varat. Liknande mönster observeras för bear-marknader, vilka också tenderar att vara persistenta, särskilt under perioder med stigande räntor. Sammantaget indikerar resultaten att marknadsregimer är persistenta tillstånd, där längden på en pågående regim har betydelse för sannolikheten att den fortsätter.

Ang och Bekaert (2002) analyserar marknadsregimer ur ett investeringsperspektiv, med fokus på internationell portföljallokering. Studien problematiserar antagandet om konstanta korrelationer mellan marknader och undersöker i stället hur dessa varierar över tid. För detta tillämpas en Markov-switching-modell där avkastning, volatilitet och korrelationer mellan olika länder modelleras som tidsvarierande.

Bakgrunden till studien är att många investerare utgår från att diversifiering alltid bidrar till att minska risk. Resultaten visar dock att korrelationer mellan marknader tenderar att öka under bear-marknader, samtidigt som volatiliteten är hög (Ang och Bekaert, 2002). Detta innebär att marknader i större utsträckning rör sig tillsammans under perioder av finansiell oro, vilket minskar effekten av diversifiering när den behövs som mest. Slutsatsen är att diversifiering generellt kan bidra till att minska risk, men att dess effektivitet är begränsad under krisperioder.

Sammantaget visar tidigare litteratur att marknadsregimer tenderar att vara persistenta, där sannolikheten att kvarstå i samma tillstånd ofta är hög. Studierna visar även att dessa regimer kännetecknas av tydliga skiften i volatilitet, avkastning och korrelationsstrukturer mellan marknader. Vidare framkommer det att både volatilitet och korrelationer tenderar att förändras under perioder av finansiell oro. Detta ligger till grund för valet av tidsperiod i den aktuella studien, där ambitionen är att inkludera perioder präglade av betydande marknadsoro och extrema marknadsförhållanden. Med utgångspunkt i tidigare forskning tillämpas därför en Gaussisk Dold Markovmodell för att identifiera och klassificera marknadsregimer i S&P 500-indexet. Den tidigare litteraturen har därmed bidragit med både en teoretisk och metodologisk grund för vår studie.

3. Metod och modell

Markovmodeller implementeras för att modellera latenta marknadsregimer i finansiella tidsserier, där dessa regimer inte är direkt observerbara utan måste estimeras statistiskt (Haase & Neuenkirch, 2023). I denna studie tillämpas den Gaussiska modellen (GHMM) för att identifiera dessa latent tillstånd.

3.1 Datadefinition

Tidsindexen betecknas med $t = 1, \dots, T$. Vid varje tidpunkt observeras en vektor $x_t \in \mathbb{R}^d$ där x_t representerar modellens inputvariabel. I vår studie finns följande två modeller:

RAW-modellen är den enkla varianten där daglig avkastning används (return):

- $x_t = r_t$ där $r_t = (P_t - P_{t-1}) / P_{t-1}$, där P_t = stängningspris (Close) vid tidpunkt t

Vidare används en utökad modell som inkluderar volatilitet och handelsvolym, den benämns som FET-modell. Denna modell använder en variabelvektor $x_t = (r_t, f_{1,t}, f_{2,t})$ där samtliga $f_{i,t}$ representerar de variabler som modellen inkluderar utöver r_t .

3.2 Observationsekvation och parameterestimering

Observationerna antas vara beroende av det latent tillståndet och följer en Gaussisk fördelning (Bishop, 2006).

$x_t \mid S_t = i \sim N(\mu_i, \Sigma_i)$ där:

- μ_i är medelvärdet i tillstånd i .
- Σ_i är kovariansmatrisen i tillstånd i och beskriver både varians och samvariation mellan variablerna.

Vidare så definieras modellens parametrar som:

$\theta = \{\pi, A, \mu_i, \Sigma_i\}$ där:

- π = initiala tillståndssannolikheter
- A = övergångsmatrisen
- μ_i, Σ_i = medelvärde och varians i de olika tillstånden

Parametrarna estimeras med hjälp av maximum likelihood.

Eftersom likelihood-funktionen för en GHMM inte kan maximeras analytiskt tillämpas en iterativ optimeringsmetod i form av Baum-Welch-algoritmen. Denna algoritm är en variant av Expectation-Maximization (EM) och växlar mellan två steg: ett E-steg, där de förväntade tillståndssannolikheterna beräknas givet nuvarande parameterskattningar, samt ett M-steg, där modellens parametrar uppdateras för att maximera den förväntade likelihood-funktionen. Enligt Rabiner (1989) konvergerar algoritmen mot ett lokalt maximum av likelihood-funktionen, vilket möjliggör skattning av modellens parametrar.

3.3 Latenta tillstånd

Marknaden antas befinna sig i ett latent tillstånd vid varje tidpunkt, vilket kan uttryckas som $S_t \in (1, \dots, K)$ där S_t representerar marknadsregimen vid tidpunkt t , I vår modell motsvarar $K = 2$ bull- och bear-marknader, samt $K = 3$ där ett tredje tillstånd introduceras för att representera en neutral marknadsfas.

3.4 Markov-egenskap och övergångssannolikhet

Processen för att identifiera tillstånd antas följa en Markovkedja (Rabiner, 1989):

$$- P(S_t | S_{t-1}, \dots, S_1) = P(S_t | S_{t-1})$$

Detta innebär att sannolikheten att befinna sig i ett visst tillstånd vid tidpunkt t enbart beror på tillståndet vid föregående tidpunkt. All tidigare historisk information, utöver det senaste tillståndet, kan därmed endast påverka tillståndet indirekt genom det senaste tillståndet. Detta antagande reducerar modellens komplexitet och möjliggör att dynamiken i tillståndsövergångarna kan beskrivas med hjälp av en övergångsmatrix.

Övergångssannolikheten definieras som nedan:

$$- P(S_t = j | S_{t-1} = i) = a_{ij} \text{ där } a_{ij} \text{ är sannolikheten att tillståndet går från } i \text{ till } j. \text{ Det är dessa sannolikheter som bildar övergångsmatrisen:}$$

$$- A = \begin{bmatrix} a_{BB} & a_{BN} & a_{BU} \\ a_{NB} & a_{NN} & a_{NU} \\ a_{UB} & a_{UN} & a_{UU} \end{bmatrix}$$

Där U representerar bull-marknad, B bear-marknad och N ett neutralt tillstånd. Exempelvis representerar a_{BN} sannolikheten att marknaden övergår från bear-marknad till ett neutralt tillstånd.

En central egenskap hos övergångsmatrisen är att varje rad summerar till 1, vilket innebär att den utgör en sannolikhetsfördelning över alla möjliga framtida tillstånd givet det nuvarande tillståndet, formellt: $a_{iB} + a_{iN} + a_{iU} = 1$.

I modeller med enbart två tillstånd, bull och bear, reduceras övergångsmatrisen till dimensionen 2×2 . Även i detta fall gäller att varje rad summerar till 1, då samma sannolikhetsprinciper tillämpas.

3.5 Inferens (Filtrering)

För att estimeras det mest sannolika tillståndet vid varje tidpunkt implementeras forward-algoritmen, även kallad filtrering. Metoden används ofta inom Markovmodeller för inferens i sekventiella data (Zucchini et al., 2016). Denna metod beräknar den filtrerade sannolikheten:

$P(S_t = i \mid x_{1:t})$ för en given tidpunkt t

vilket motsvarar sannolikheten att systemet befinner sig i tillstånd i vid tidpunkt t , givet all tillgänglig information fram till och med tidpunkt t . Metoden baseras således enbart på historiska observationer och exkluderar framtida information.

Det predikterade tillståndet erhålls därefter som det tillstånd som maximerar denna sannolikhet:

$$\hat{S}_t = \arg \max_i P(S_t = i \mid x_{1:t}).$$

3.6 Definitioner av marknadsregimer

GHMM är en modell där de latent tillstånden saknar en direkt ekonomisk tolkning. För att möjliggöra en sådan tolkning beräknas den genomsnittliga dagliga avkastningen $\bar{r}_i$ för varje tillstånd i , baserat på de observationer som tilldelats respektive tillstånd. Utifrån dessa genomsnittliga avkastningar kan tillstånden därefter klassificeras som bull-, bear- eller neutrala marknadsregimer enligt rangordning.

Modell	Klassificering
2-tillstånd	$\bar{r}_{BEAR} < \bar{r}_{BULL}$
3-tillstånd	$\bar{r}_{BEAR} < \bar{r}_{NEUTRAL} < \bar{r}_{BULL}$

Vid modeller med tre tillstånd ges möjligheten att identifiera ett tredje, mellanliggande tillstånd. Detta innebär att vissa observationer kan klassificeras som neutrala, vilket gör att modellen inte enbart särskiljer mellan bull- och bear-marknader. Det neutrala tillståndet kan tolkas som en konsolideringsfas, där marknaden varken uppvisar en tydlig uppåt- eller nedåtgående trend.

3.7 AIC och BIC

För att objektivet utvärdera vilken modellstruktur, med två respektive tre tillstånd, som ger bäst balans mellan anpassning och komplexitet, används informationskriterierna AIC (Akaike Information Criterion) och BIC (Bayesian Information Criterion) (Hastie et al., 2009):

$$AIC = 2k - 2 \ln L \text{ och } BIC = k \ln(n) - 2 \ln L$$

- $k = \text{mängden fria parametrar}$
- $n = \text{antalet observationer}$
- $L = \text{log-likelihood-värde}$

Värdena på AIC och BIC speglar modellens anpassningsförmåga i relation till dess komplexitet, där lägre värden signalerar en bättre avvägning mellan god modellanpassning och enkelhet. BIC tenderar dessutom att straffa komplexa modeller hårdare än AIC.

För att kunna beräkna AIC och BIC krävs en bestämning av antalet fria parametrar k . För en GHMM med K tillstånd, d förklarande variabler och full kovariansstruktur ges antalet fria parametrar enligt följande formel:

$$k = (K - 1) + K(K - 1) + Kd + K * \frac{d(d + 1)}{2}$$

Där termer motsvarar initiala tillståndssannolikheter π , $(K - 1)$, övergångsmatrisen A , $K(K - 1)$, medelvärde μ_i , Kd , samt kovariansmatriser Σ_i , $K * \frac{d(d+1)}{2}$, ingår.

3.8 Mått och utvärdering

Baserat på jämförelsen mellan modellernas klassificeringar och den referensklassificering som erhålls genom LT-algoritmen Lunde och Timmermann (2004), vilken används som studiens ground truth, konstrueras en förväxlingsmatris. Utifrån denna definieras True Positive (TP) som antal dagar med korrekt identifierade bear-marknader, medan True Negative (TN) avser antalet dagar som korrekt identifierats som bull-marknad. Vidare betecknar False Positive (FP) antal dagar där modellen felaktigt klassificerar en bull-marknad som en bear-marknad, medan False Negative (FN) avser dagar där en faktisk bear-marknad inte identifierades av modellen. Utifrån dessa komponenter i förväxlingsmatrisen definieras ett antal mått såsom accuracy, precision, recall och F1-score (James, et al., 2021).

$$\begin{aligned} - \text{Accuracy} &= \frac{TP+TN}{TP+TN+FP+FN} \\ - \text{Recall} &= \frac{TP}{TP+FN} \\ - \text{Precision} &= \frac{TP}{TP+FP} \\ - F1 &= 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \end{aligned}$$

* *Accuracy innebär andelen dagar som modellen klassificerar korrekt, oavsett om det är en bull- eller bear-dag.*

* *Recall avser andelen faktiska bear-dagar som modellen korrekt identifierar och visar därmed hur väl modellen fångar upp bear-marknader.*

* *Precision avser andelen dagar av modellens bear-klassificeringar som faktiskt utgör bear-dagar, måttet visar därmed hur tillförlitlig modellens bear-klassificering är.*

* *Slutligen är F1 ett mått som väger ihop precision och recall till ett sammansatt tal, ett högt tal indikerar att modellen är träffsäker.*

Dessa mått utgör grunden för att bedöma vilken modell som uppvisar bäst prestanda. Modeller med tre tillstånd ($K = 3$), vilka inkluderar ett neutralt mellantillstånd, behandlas separat i utvärderingen. Observationer i neutralt tillstånd exkluderas från mått såsom accuracy och F1-score, då LT-algoritmen endast bildar referensklasser för bull- och bear-marknader och saknar en motsvarande ground truth för neutrala perioder, vilket innebär att en rättvis jämförelse mellan modeller med två respektive tre tillstånd annars inte är möjlig.

För att komplettera utvärderingen introduceras även måttet *coverage*, vilket anger andelen handelsdagar som modellen ger en binär klassificering som bull eller bear. Detta mått är särskilt relevant för modeller med tre tillstånd, då det möjliggör en mer nyanserad analys av modellens beteende över tid. Dessa mått tillsammans med jämförelse mot ground truth, AIC och BIC är grunden för utvärderingen av modellerna.

4. Data

Datan som används i studien är hämtad från Yahoo Finance, en plattform med inriktning på den globala aktiemarknaden. Plattformen tillhandahåller omfattande marknadsdata för ett brett spektrum av finansiella tillgångar, inklusive aktieindex såsom S&P 500, enskilda aktier samt råvaror. S&P 500 valdes som studieobjekt då indexet erbjuder en omfattande historisk datamängd samt uppvisar tydliga och väldefinierade bull- och bear-marknadsfaser.

4.1 Datakälla

Eftersom finansiella marknaders trender ofta är långsiktiga till sin natur är det av vikt att använda en omfattande tidsperiod, för att möjliggöra en tillförlitlig utvärdering av de tillämpade metoderna. Tabell 1 nedan visar informationen kring datan:

Tabell 1. Datakälla..

Tillgång	Ticker	Källa	Period	Handelsdagar
S&P 500	GSPC	Yahoo Finance	2000-03-29 $\Rightarrow$ 2025-12-31	6 479

** Antal dagar avser enbart amerikanska handelsdagar, det vill säga vardagar exklusive helgdagar och nationella helgdagar*

Valet av tidsperiod baseras på ambitionen att inkludera flera betydande historiska nedgångsperioder, då skiften mellan regimer och långa marknadsfaser utgör centrala egenskaper i finansiella tidsserier (Hamilton, 1989). Den studerade perioden omfattar tre större bear-marknader: It-bubblans kollaps (2000–2002), finanskrisen (2008–2009) samt covid-nedgången (2020–2021). Detta urval säkerställer att modellerna exponeras för varierande marknadsförhållande och ges tillräckliga data för att kunna identifiera och analysera regimskiften.

4.2 Datagranskning

För studien använder vi stängningskurs (Close) som vår prisserie. Tabellen nedan redovisar deskriptiv statistik.

Tabell 2. Deskriptiv data för variabeln stängningspris (Close).

Variabler	Medelvärde	Standardavvikelse	Min	Max
Close	2 269	1 454,14	676,53	6 932,95

* Samtliga värden anges i USD (amerikanska dollar) för Tabell 2.

Stängningspriset har valts som den primära variabeln för beräkning av etikettering, avkastning samt tekniska indikatorer. För att säkerställa en rättvis modellering standardiseras datan, vilket innebär att samtliga variabler ges jämförbara skalor och därmed bidrar proportionerligt till modellen (James et al., 2021). Det görs genom $x_t^* = (x_t - \mu) / \sigma$ för samtliga variabler i studien, där:

- μ = medelvärdet för variabeln
- σ = standardavvikelsen

4.3 Etikettering

Eftersom marknadsregimerna är latenta och inte direkt observerbara i prisserien, definieras dessa genom klassificeringsetiketter. Prisdata omvandlas därmed till en binär variabel, där bull-marknader representeras av värdet 1 och bear-marknader av värdet 0. Dessa etiketter utgör den så kallade *ground truth*, vilket används som referens för att utvärdera modellerna.

4.3.1 Algoritmen

Algoritmen som tillämpas i denna studie är introducerad av Lunde & Timmermann (2004), som benämns LT-algoritm. Metoden är icke-parametrisk och implementeras för att identifiera lokala toppar och bottenar i en prisserie, utan att göra några antaganden om den underliggande prisprocessens fördelning.

Algoritmen initieras i ett bull-läge och uppdateras därefter iterativt genom att kontinuerligt följa:

- den senaste bekräftade toppen (topp) – som identifierar övergångar till bear-marknad
- den senaste bekräftade botten (botten) – som identifierar övergångar till bull-marknad

En bear-marknad definieras när priset faller med minst θ_{bear} procent från den senaste toppen, medan en bull-marknad definieras när priset stiger med minst θ_{bull} procent från den senaste botten, formellt uttrycks det på följande sätt:

$Bear_t: \frac{P_t - topp}{topp} \leq -\theta_{bear}$ och $Bull_t: \frac{P_t - botten}{botten} \geq \theta_{bull}$, där topp och botten är den senaste toppen och botten.

Parametrarna vi använder i vår studie är:

$$\theta_{bear} = 10 \% \text{ och } \theta_{bull} = 15 \%$$

4.4 Klassfördelning

När data klassificerades i bull- och bear-marknader erhöles fördelningen som presenteras i Tabell 3.

Tabell 3. Klassfördelning med hjälp av etikettering.

Bull-dagar	Bear-dagar	Bull %	Bear %
4 770	1 709	73,6 %	26,4 %

Det framgår att datasetet uppvisar en tydlig övervikt av bull-dagar, vilka utgör 73,6 procent av observationerna, medan bear-dagar utgör 26,4 procent. Denna klassobalans innebär att en modell som konsekvent klassificerar samtliga observationer som bull-marknad skulle uppnå en träffsäkerhet på 73,6 procent, utan att korrekt identifiera någon bear-marknad.

Detta illustrerar att träffsäkerhet (Accuracy) i isolation är ett otillräckligt mått för att utvärdera modellernas prestanda i detta sammanhang. Mot denna bakgrund används flera kompletterande utvärderingsmått för att erhålla en mer rättvisande bedömning av modellernas förmåga att särskilja mellan marknadsregimer. Dessa mått presenteras i metoddelen under avsnittet mått och utvärdering.

4.5 Variabler

Den utökade modellen använder sig av avkastning, volatilitet samt volym som variabler, den slutgiltiga vektorn ser ut som följande:

$$- x_t = (r_t, Volatility_60_t, Volume_ratio_t)$$

Följande nya variabler tillämpas i den utökade modellen:

- Volatility_60 = Volatilitet mäts som den rullande standardavvikelsen av avkastning över en 60-dagarsperiod. Måttet används för att kvantifiera variationen i prISRörelse, där högre värden tyder på större osäkerhet och mer volatila marknadsförhållanden, medan lägre värden tyder på en mer stabil marknad.
- Volume_ratio = Variabeln mäter relationen mellan dagens handelsvolym och dess 50-dagars rullande medelvärde. Högre värden signalerar en ökad handelsaktivitet, vilket ofta är förknippat med starkare prISRörelser och ökad marknadsintensitet.

Tabell 4. Redovisar deskriptiv statistik för variablerna volatilitet och volym.

Variabler	Medelvärde	Std	Min	Max
Volatilitet	0,010	0,006	0,003	0,046
Volym	1,007	0,193	0,000	2,200

* Notera att Std står för standardavvikelse.

4.6 Datarensning och begränsningar

Innan modellanpassning genomfördes en datarensning för att hantera saknade värden som uppstår vid beräkning av rullande variabler. De två extra variabler som ingår i FET-modellen, Volatility_60 och Volume_ratio, baseras på rullande fönster (60 och 50 dagar) och kräver därmed ett visst antal tidigare observationer för att kunna beräknas.

För att säkerställa ett komplett dataset eliminerades de inledande observationer där minst en av variablerna saknade giltigt värde. Totalt resulterade detta i att 60 rader togs bort, varvid datasetet minskade från 6 539 till 6 479 observationer.

5. Resultat och analys

5.1 Konvergens

De fyra modellerna som används i studien skattades med Baum-Welch-algoritmen, vilken introducerades i avsnitt 3.2. Resultatet presenteras i Tabell 5. Tabellen visar att antalet iterationer varierar mellan modellerna, vilket indikerar variationer i modellernas komplexitet och i de använda variabel-uppsättningarna.

Det mest centrala resultatet är att samtliga modeller konvergerade under träningen. Detta innebär att varje modell nådde ett lokalt maximum av likelihood-funktionen och därmed erhöll stabila parameterskattningar.

Tabell 5. Konvergens för modellerna.

Modell	Features	Konvergens	Antal iterationer
RAW-2	Avkastning	Ja	26
RAW-3	Avkastning	Ja	106
FET-2	Avkastning, Volatilitet, Volym	Ja	23
FET-3	Avkastning, Volatilitet, Volym	Ja	43

5.2 Tillståndsmappning

Efter skattningen av parametrarna och filtrering av tillstånd mappades varje tillstånd till en marknadsregim baserat på den empiriska genomsnittliga avkastningen ($\bar{r}_i$), genom rangordningsproceduren i avsnitt 3.6. Resultatet av denna mappning presenteras i Tabell 6.

Tabell 6. Mappning av tillstånd.

Modell	Tillstånd	$\bar{r}_i$ (%)	Mappning	Antal dagar
RAW-2	0	+ 0,061	Bull	4 658
RAW-2	1	- 0,047	Bear	1 821
RAW-3	0	- 0,009	Neutral	2 933
RAW-3	1	- 0,026	Bear	497
RAW-3	2	+ 0,078	Bull	3 049
FET-2	0	+ 0,046	Bull	3 974
FET-2	1	+ 0,006	Bear	2 505
FET-3	0	+ 0,025	Neutral	2 315
FET-3	1	- 0,041	Bear	698
FET-3	2	+ 0,049	Bull	3 466


Resultaten visar att modellerna med två tillstånd generellt uppvisar en tydlig uppdelning mellan bull- och bear-marknader. För RAW-2 observeras en klassisk struktur, där bull-tillståndet kännetecknas av positiv genomsnittlig avkastning (+0,061%), medan bear-tillståndet uppvisar negativ avkastning (-0,047%).

För FET-2 skiljer sig resultatet, då båda tillstånden uppvisar positiva genomsnittliga avkastningar (+0,046% respektive +0,006%). Detta signalerar att modellen inte identifierar ett traditionellt bear-tillstånd baserat enbart på negativ avkastning. I stället tyder resultatet på att det tillstånd som klassificeras som ”bear” i FET-2 snarare fångar perioder präglade med relativt svagare avkastning i kombination med andra marknadsegenskaper, såsom ökad volatilitet och handelsvolym.


Detta antyder att inkluderingen av ytterligare variabler leder till en alternativ tolkning av marknadsregimer, där ”bear” inte enbart definieras av negativ avkastning, utan även av förändringar i marknadens dynamik.

För att underlätta tolkningen av mappningen illustrerar Figur 1-3 hur modellerna klassificerar observationerna över tid. Diagram för FET-3 och RAW-2 hänvisas till appendix.


Figur 1. Ettikerade marknadsregimer enligt L-T algoritmen (ground truth)



Figur 2. RAW-3 filtrerat estimerade marknadsregimer.



Figur 3. FET-2 filtrerat estimerade marknadsregimer i diagram.



Vid en första granskning av RAW-3 framgår det att modellen uppvisar frekventa skiften mellan bull-, bear- och neutrala tillstånd. De gula (neutrala) och gröna (bull) segmenten dominerar stora delar av tidsserien, vilket i kombination med resultaten i Tabell 5 tydligt tyder på att endast ett begränsat antal observationer (497) klassificeras som bear-marknad.

För FET-2 observeras i stället ett markant annorlunda mönster, där klassificeringen präglas av mer utdragna och sammanhängande perioder. Detta tyder på att de identifierade regimerna är mer persistenta och stabila över tid. Vid jämförelse med ground truth framgår dessutom en hög grad av överensstämmelse, vilket stärker intrycket att modellen fångar de övergripande marknadsregimerna på ett effektivt sätt.

5.3 Prestanda

Vidare exkluderas de observationer som tilldelas det neutrala tillståndet vid beräkning av vissa utvärderingsmått. För modeller med två tillstånd (RAW-2 och FET-2) förekommer inget neutralt tillstånd, vilket innebär att samtliga observationer klassificeras som antingen bull eller bear och därmed ger en *coverage* på 100 %.

För modeller med tre tillstånd reduceras däremot *coverage*, eftersom observationer som klassificeras som neutrala tillstånd exkluderas från den binära utvärderingen. Måttet *coverage* definieras således som andelen dagar där modellen ger en entydig klassificering som bull eller bear. Tabell 7 visar resultatet.

Tabell 7. Samtliga versioners prestanda.

Modell	Coverage	Accuracy	Bear Recall	Bear Precision	F1
RAW-2	100 %	0,780	0,616	0,580	0,782
RAW-3	54,7 %	0,889	0,585	0,720	0,884
FET-2	100 %	0,786	0,828	0,560	0,797
FET-3	64,3 %	0,868	0,649	0,460	0,877

Analysen inleds med modellen RAW-2. Som tidigare diskuterats uppvisar denna modell en *coverage* på 100 %, vilket innebär att samtliga observationer klassificeras som antingen bull eller bear. Modellen uppnår en *accuracy* på 0,780, ett F1-score på 0,782 samt en *bear recall* på 0,616. RAW-2 fungerar därmed som en relevant baslinje för vidare jämförelse.

Den utökade modellen RAW-3 uppvisar däremot en *coverage* på 54,7 %, vilket innebär att modellen endast klassificerar drygt hälften av observationerna som bull eller bear. För dessa klassificerade dagar uppnås en högre *accuracy* på 0,889 och ett F1-score på 0,884, medan *bear recall* uppgår till 0,585.

Resultaten påvisar att RAW-3 uppvisar en högre träffsäkerhet än RAW-2, men detta gäller enbart för den delmängd av data som modellen faktiskt klassificerar. De neutrala tillstånden, som exkluderas från den binära utvärderingen, utgör 45,3 % av observationerna, motsvarande 2 933 dagar.

Den något lägre *bear recall* i RAW-3 jämfört med RAW-2 kan förklaras av att modellen är mer restriktiv i sin klassificering av bear-marknader. Antalet dagar som klassificeras som bear är betydligt lägre i RAW-3 (497 dagar) jämfört med RAW-2 (1 821 dagar), vilket innebär att färre faktiska nedgångsperioder identifieras.

En annan aspekt att notera är att RAW-3 uppvisar en högre *bear precision* än RAW-2 (0,720 jämfört med 0,580). Detta indikerar att en större andel av de dagar som modellen klassificerar som bear-marknader faktiskt utgör bear-marknader. Resultatet tyder på att modellen med tre

tillstånd är mer selektiv i sin identifiering av bear-marknader än modellen med två tillstånd. Den högre precision uppnås dock på bekostnad av en lägre recall, vilket innebär att färre faktiska bear-marknader inte identifieras av modellen.

Vidare analyseras modellerna med utökad variabeluppsättning (FET-modellerna). För modellen FET-2 observeras en accuracy på 0,786, ett F1-score på 0,797, bear recall på 0,828 och en precision på 0,560.

Jämfört med motsvarande RAW-modell framträder en tydlig förbättring i modellens förmåga att fånga nedgångsperioder, där bear recall ökar med cirka 0,25 enheter. Detta antyder att inkludering av ytterligare variabler, såsom volatilitet och handelsvolym, bidrar till en mer effektiv identifiering av bear-marknader. Resultatet antyder därmed att dessa variabler tillför information som inte fullt ut fångas av enbart avkastning, särskilt i samband med marknadsnedgångar.

FET-3 uppvisar liknande accuracy (0,868) och F1-score (0,877) som RAW-3, vilket kan tolkas som att det neutrala tillståndet, i enlighet med tidigare resonemang, fungerar som en brusreducering i datan. Detta innebär att observationer som i tvåtillståndsmodellerna måste klassificeras som antingen bull- eller bear-marknader i stället kan fångas upp av ett mellanliggande tillstånd. Vidare tyder resultatet att inkluderingen av volatilitet och volym bidrar till att FET-3 uppvisar en förbättrad förmåga att detektera nedgångsperioder jämfört med RAW. Samtidigt tyder resultaten på att inkluderingen av dessa ytterligare variablerna bidrar till att modellerna blir mindre selektiva, vilket återspeglas i de lägre värdena på bear precision. Vilket innebär att de utökade modellerna identifierar fler nedgångsperioder, men på bekostnad av en ökad andel felaktiga bear-klassificeringar.

En vidare analys av resultaten från Tabell 7 görs genom att kombinera F1-score och coverage till ett gemensamt mått, F1 x coverage. Detta motiveras av att dessa mått är beroende av varandra, då en modell med högt F1-score men låg coverage endast presterar väl på en begränsad del av datamängden. Resultaten ser vi i Tabell 8 nedan.

Tabell 8. Tabell för prestationsmått, F1 x coverage.

Modell	Coverage	F1	F1 x coverage
RAW-2	100 %	0,782	0,782
FET-2	100 %	0,797	0,797
RAW-3	54,7 %	0,884	0,484
FET-3	64,3 %	0,877	0,563

Resultaten visar att modeller med full coverage bibehåller sina F1-värden, medan modeller med lägre coverage får en tydlig reducering i detta kombinerade mått. Särskilt framträdande är att den modell som uppvisar högst F1-score också påverkas mest negativt vid justering för coverage. Detta tyder på att en hög träffsäkerhet inte nödvändigtvis kompenserar för en låg andel klassificerade observationer. Följaktligen framstår modeller med hög coverage som mer robusta i en praktisk tillämpning, då de levererar konsekventa klassificeringar över en större del av datamängden. Inkluderingen av ytterligare variabler hjälper främst för att öka coverage i 3-tillståndsmodellerna utan att minska precision, där vi ser att FET-3 uppvisar högre coverage samtidigt som den erhåller ungefär likadant F1-score som RAW-3.

5.4 Skattade Gaussiska parametrar

Tabell 9. Skattade Gaussiska parametrar (avkastning) för modell RAW-2.

Regim	Skattad μ (%)	Skattad σ (%)	$\bar{r}_i$ (%)
Bull	+ 0,081	+ 0,704	+ 0,061
Bear	- 0,092	+ 1,963	- 0,047

Tabell 10. Skattade Gaussiska medelvärden för respektive variabel, FET-2.

Regim	Volatilitet μ (%)	Volym μ (%)	Avkastning μ (%)
Bull	- 0,546	- 0,034	+ 0,022
Bear	+ 0,890	+ 0,056	- 0,036

Tabell 11. Skattade Gaussiska standardavvikelser för respektive variabel, FET-2.

Regim	Volatilitet σ (%)	Volym σ (%)	Avkastning σ (%)
Bull	+ 0,263	+ 0,885	+ 0,594
Bear	+ 1,113	+ 1,161	+ 1,432

Vid en analys av Tabell 9 framgår det att den skattade genomsnittliga avkastningen i bear-tillståndet uppgår till - 0,092 %, medan motsvarande värde förr bull-tillståndet är +0,081 %. Vidare visar den skattade standardavvikelsen att bear-marknader kännetecknas av betydligt högre volatilitet, där volatiliteten är ungefär 2,79 gånger högre än i bull-tillståndet (+ 1,963 jämfört med + 0,704).

Detta resultat är i linje med den så kallade leverage-effekten (Black, 1976), vilken beskriver det empiriska sambandet där negativa avkastningar är förknippade med ökad volatilitet.

Att modellen, utan explicit antagande om detta samband, identifierar ett sådant mönster signalerar att de latent tillståndet fångar underliggande ekonomiska strukturer. Detta tyder på att tillståndet inte enbart är statistiskt konsistent, utan även har ekonomisk relevans.

Vidare analyseras de skattade Gaussiska parametrarna för den utökade modellen och redovisas i Tabell 10 och 11. Bull-tillståndet uppvisar ett negativt medelvärde (-0,546), medan bear-tillståndet kännetecknas av ett positivt medelvärde (+0,890). Detta tyder på att bear-tillståndet förknippas med högre volatilitet.

Sedan observeras att spridningen (standardavvikelsen) av avkastning är avsevärt högre i bear-tillståndet (+1,113) jämfört med bull-tillståndet (+0,263), vilket kan tolkas att nedgångsperioder präglas av större osäkerhet och är i linje med volatilitetsmått. I kontrast till detta uppvisar volym och avkastning ett medelvärde nära noll i båda tillstånden, vilket tyder på att deras direkta bidrag till klassificering är begränsade i denna modell. Dessa resultat kan relateras till tidigare observationer där FET-2 uppvisade positiva genomsnittliga avkastningar i både bull- och bear-tillstånd. Detta tyder på att modellen i högre grad baserar sin klassificering på volatilitetsnivåer snarare än enbart genomsnittlig avkastning. Därmed fångar modellen i större utsträckning marknadsförhållanden, präglade av osäkerhet och instabilitet, snarare än enbart riktningen i prISRörelser, vilket skiljer den från RAW-modellerna.

5.5 Övergångsmatris

För att vidare analysera modellernas dynamiska egenskaper studeras de skattade övergångsmatriserna, vilka anger den dagliga sannolikheten att marknaden går från ett tillstånd till ett annat. Övergångsmatrisen utgör därmed ett centralt mått både på regimens persistens och på hur övergångar mellan tillstånden struktureras. Resultatet för de fyra modellvarianterna presenteras i Tabell 12 nedan.

Tabell 12. Övergångsmatriser för samtliga modeller.

	RAW-2			RAW-3		
Bull	0,989	0,011	Neutral	0,965	0,008	0,027
Bear	0,028	0,972	Bear	0,040	0,960	0,000
	Bull	Bear	Bull	0,025	0,000	0,975
				Neutral	Bear	Bull
	FET-2			FET-3		
Bull	0,995	0,005	Neutral	0,987	0,007	0,006
Bear	0,009	0,991	Bear	0,034	0,958	0,007
	Bull	Bear	Bull	0,002	0,003	0,995
				Neutral	Bear	Bull

* Fetmarkerade värden visar sannolikheten att stanna i samma tillstånd.

I Tabell 12 framträder en tydligt persistent regimstruktur. Diagonalvärdena är genomgående höga i samtliga modeller och varierar mellan 0,958 och 0,995, vilket innebär att marknaden med minst 95,8 procents sannolikhet stannar kvar i samma regim från en dag till nästa. Detta bekräftar bilden av bull- och bear-marknader som strukturellt persistenta tillstånd snarare än slumpmässiga dagliga skiften, och resultatet är förenligt med den ekonomiska litteraturens beskrivning av marknadsregimer (Lunde & Timmermann, 2004).

För de tre tillståndsmoellerna framträder två särskilt intressanta mönster. I RAW-3 är de skattade sannolikheterna för direkt övergång mellan bull och bear lika med noll i båda riktningarna, vilket innebär att marknaden alltid passerar det neutrala tillståndet vid ett regimskifte. Detta påvisar att övergångar mellan uppgångs- och nedgångsfaser inte är abrupta utan föregås av en konsolideringsfas.

I FET-3 observeras att övergångssannolikheterna mellan de olika tillstånden är relativt lika. Exempelvis är sannolikheten att övergå från bull till neutral 0,2 %, medan sannolikheten att övergå från bull till bear uppgår till 0,3 %. Tillsammans med tidigare observationer i avsnitt 6.2 och 6.4 stärker detta tolkningen att FET-3:s tre tillstånd inte motsvarar tre klassiska marknadsregimer, utan snarare en uppdelning baserad på volatilitetsstruktur.

5.6 AIC och BIC

Tabell 13. Modelljämförelse med AIC och BIC.

Modell	k	logL	AIC	BIC
RAW-2	7	- 7 849	15 712	15 760
RAW-3	14	- 7 557	15 142	15 236
FET-2	21	- 21 283	42 609	42 751
FET-3	35	- 18 634	37 338	37 576

För ytterligare utvärdering av modellernas prestanda användes informationskriterierna AIC och BIC. Av Tabell 13 framgår att FET-2 modellen uppvisar de högsta värdena, vilket i detta sammanhang indikerar den sämsta avvägningen mellan modellanpassning och komplexitet. Även FET-3 uppvisar relativt höga värden, vilket tyder på att de utökade modellerna generellt presterar sämre än motsvarande RAW-modeller enligt dessa kriterier.

Det bör dock noteras att FET- och RAW-modellerna skattas på något olika antal observationer, då beräkningen av volatilitet och volym medför att ett mindre antal observationer exkluderas i FET-modellerna. Skillnaden är dock begränsad i förhållande till det totala urvalet och bedöms inte ha någon avgörande påverkan på skattningarna då skillnaderna mellan RAW- och FET-modellerna är så stora.

Vid en jämförelse av RAW-modellerna framgår att dessa uppvisar betydligt lägre värden. Särskilt utmärker sig RAW-3, som erhåller de bästa resultaten vad gäller log-likelihood, AIC och BIC. Detta indikerar att RAW-3 uppnår den mest fördelaktiga balansen mellan modellens anpassningsförmåga och dess komplexitet, och därmed framstår som den statistiskt bäst anpassade modellen.

Förbättringen av log-likelihood för RAW-3 kan motiveras av införandet av ett tredje tillstånd, vilket möjliggör en mer flexibel representation av data. Trots att detta innebär en ökning i antalet parametrar, kompenseras den ökade komplexiteten av en förbättrad modellanpassning.

Sammantaget tyder resultatet på att de ytterligare variabler som inkluderas i FET-modellerna inte förbättrar den statistiska anpassningen i detta sammanhang, utan snarare bidrar till en sämre förklaringsförmåga trots dess komplexitet.

5.7 Sammanfattning

Tabell 13. Modelljämförelse med samtliga mått.

Modell	Coverage	Accuracy	F1	Bear Recall	AIC/BIC-rank	F1 x coverage
RAW-2	100 %	0,780	0,782	0,616	2	0,782
RAW-3	54,7 %	0,889	0,884	0,585	1	0,483
FET-2	100 %	0,786	0,797	0,828	4	0,797
FET-3	64,3 %	0,868	0,877	0,649	3	0,564

* Fetmarkerade värden indikerar det bästa utfallet inom respektive mått.

I Tabell 13 sammanställs samtliga resultat och utvärderingsmått för de analyserade modellerna. Vid en första anblick framstår RAW-3 som den mest framträdande modellen, då den uppvisar högst accuracy och F1-score, samtidigt som den även erhåller de lägsta värdena för AIC och BIC. Detta indikerar att modellen är den statistiskt bäst anpassade bland de studerade alternativen.

Parallellt är modellens coverage begränsad till 54,7 %, vilket innebär att en betydande andel av observationerna inte klassificeras. Detta reducerar modellens praktiska användbarhet i jämförelse med RAW-2 och FET-2, vilka båda uppvisar full coverage.

Vidare framgår att FET-2 är den enda modellen som kombinerar full coverage med en tydligt högre bear recall än övriga modeller. Som tidigare diskuterats kan detta förklaras av att klassificeringen i FET-2 i större utsträckning baseras på volatilitet snarare än enbart genomsnittlig avkastning, vilket förbättrar modellens förmåga att identifiera nedgångsperioder.

6. Diskussion och slutsatser

För att undersöka hur väl en GHMM kan identifiera bull- och bear-marknader formulerades tre frågeställningar i denna studie. I detta avsnitt besvaras dessa utifrån resultaten i föregående avsnitt.

Den första frågeställningen avsåg *hur väl en GHMM baserad på rådata i form av avkastning (return) kan identifiera bull- och bear-regimer i S&P 500*. Resultaten från modellen RAW-2 visade att modellen uppnådde relativt hög accuracy och F1-score, vilket indikerar en god övergripande klassificeringsförmåga. Samtidigt identifierade modellen ungefär 62 % av de faktiska bear-marknaderna, vilket tyder på en begränsad förmåga att detektera nedgångsperioder.

De skattade Gaussiska parametrarna var därutöver väl förenliga med de empiriska observationerna i datan. Övergångsmatrisen visade att regimerna uppvisar hög persistens, där sannolikheten att kvarstå i samma tillstånd låg i intervallet 95,8–99,5 %. Detta är i linje med tidigare forskningen av Ang & Bekaert (2002) och Hamilton (1989), vilka också finner att marknadsregimer tenderar att vara långvariga och stabila över tid.

Sammanfattningsvis indikerar resultaten att en GHMM baserad enbart på genomsnittlig avkastning kan identifiera marknadsregimer med relativt god precision och övergripande träffsäkerhet. Detta sker däremot på bekostnad av modellens begränsade förmåga att fånga bear-marknader, där klassificeringsförmågan framstår som svagare.

Den andra frågeställningen avsåg *huruvida inkluderingen av volatilitet och volym som ytterligare variabler bidrar till förbättrad klassificeringsförmåga*. Det mest framträdande resultatet i jämförelse med RAW-2 var att inkluderingen av dessa variabler ökade bear recall med cirka 20 procentenheter, vilket indikerar att volatilitet och handelsvolym innehåller viktig information som inte fångas upp enbart av genomsnittlig avkastning.

Vidare visar de skattade Gaussiska parametrarna att volatiliteten i bear-regimen är betydligt högre än i bull-regimen, vilket tyder på att nedgångsperioder präglas av större marknadsosäkerhet och kraftigare prisrörelser. Detta är konsistent med resultaten från Haase & Neuenkirch (2023), vilka finner att volatilitetstillstånd samvarierar med definitioner av bull- och bear-marknader.

FET-2 uppvisade dessutom det högsta värdet för F1 x coverage bland samtliga modeller, vilket innebär att modellen ger den mest välbalanserade avvägningen mellan täckningsgrad och träffsäkerhet. Sammantaget indikerar resultaten att inkluderingen av volatilitet och volym bidrar till en tydligt förbättrad modell trots sämre anpassning till data (mätt med informationskriterier). Trots att FET-2 uppvisar liknande accuracy och F1-score som RAW-2, har modellen en avsevärt bättre förmåga att korrekt identifiera nedgångsperioder, vilket är

särskilt viktigt ur ett investerings- och riskhanteringsperspektiv, där förmågan att identifiera marknadsnedgångar ofta väger tyngre än hög övergripande träffsäkerhet.

Fråga tre behandlade *huruvida införandet av ett ytterligare tillstånd kunde förbättra modellernas förmåga att identifiera bull- och bear-marknader*. Resultatet indikerar att införandet av ett neutralt tillstånd fungerar som ett slags brusfilter. I exempelvis RAW-3 observeras det att marknaden inte övergår direkt från bull till bear, utan i stället passerar genom det neutrala tillståndet. Detta är i linje med Lunde och Timmermann (2004), som framhåller att marknadsregimer tenderar att vara persistenta över tid. Införandet av ett tredje tillstånd bidrar därmed till en förbättrad förmåga att fånga marknadsdynamiken jämfört med modellerna med två tillstånd. Vidare uppvisar RAW-3 de lägsta värdena för AIC och BIC, vilket indikerar den bästa avvägningen mellan modellens komplexitet och dess anpassningsförmåga till den observerade datan.

Slutligen beror valet av modell på studiens syfte och användningsområde. Modellerna med två tillstånd är mest lämpliga när målet är att inkludera samtliga observationer i klassificeringen, där FET-2 särskilt utmärker sig genom sin goda förmåga att detektera marknadsnedgångar. Om syftet i stället är att uppnå en mer tillförlitlig klassificering av marknadsregimer framstår modellerna med tre tillstånd som mer ändamålsenliga, då dessa uppvisar högre accuracy och F1-värden. Bland dessa framstår RAW-3 som den statistiskt starkaste modellen enligt AIC och BIC, medan FET-3 uppvisar en något starkare förmåga att fånga nedgångsperioder.

Studien visar att GHMM utgör en användbar statistisk metod för att identifiera latent marknadsregimer. Resultatet indikerar att valet av modell bör baseras på en avvägning mellan praktisk användbarhet, tolkningsbarhet och modellflexibilitet.

Det är viktigt att beakta studiens begränsningar vid tolkningen av resultaten. En central begränsning är att analysen enbart baseras på data från S&P 500, vilket begränsar möjligheten att generalisera resultaten till andra aktiemarknader eller tidsperioder. Resultaten bör därför främst betraktas som representativa för den undersökta marknaden under den studerade tidsperioden.

Vidare utgår definitionerna av bull- och bear-marknader från LT-algoritmen utvecklade av Lunde och Timmermann (2004). Eftersom klassificeringen av marknadsregimer är beroende av de valda tröskelvärdena kan alternativa definitioner resultera i andra klassificeringar och därmed påverka modellernas resultat.

En sista avsevärd begränsning är att studien använder en Gaussisk Dold Markovmodell, vilket antar att observationerna inom varje tillstånd är normalfördelade. Finansiella tidserier uppvisar dock ofta extrema värden som förekommer oftare än vad normalfördelningen förutsätter, modellen utgör därför en approximation av den underliggande datan.

Vidare forskning skulle kunna undersöka alternativa emissionsfördelningar för att bättre fånga de tunga svansarna, där en t-fördelning vore relevant. Det vore även en idé att inkludera ytterligare variabler för att erhålla en djupare förståelse av marknadsdynamiken och analysera vilka variabler som har störst påverkan på modellernas klassificeringsförmåga. Slutligen skulle framtida studier kunna applicera modellen på andra tillgångsslag och marknader för att undersöka modellens generaliserbarhet under olika marknadsförhållanden.

7. Referenslista

Ang, A. & Bekaert, G. (2002). International asset allocation with regime shifts. *The Review of Financial Studies*, 15(4), 1137–1187.

Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. New York: Springer.

Black, F. (1976). Studies of stock price volatility changes. *Proceedings of the 1976 Meetings of the American Statistical Association*, Business and Economic Statistics Section, 177-181.

Haase, F. & Neuenkirch, M. (2023). Predictability of bull and bear markets: A new look at forecasting stock market regimes (and returns) in the US. *International Journal of Forecasting*, 39(2), 843-861.

Hamilton, J.D. (1989). A New Approach to the Economic Analysis of Nonstationary Time Series and the Business Cycle, *Econometrica*, 57(2), pp. 357-384.

Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2nd ed. New York: Springer.

James, G., Witten, D., Hastie, T. & Tibshirani, R. (2021). *An Introduction to Statistical Learning: with Applications in R*. 2nd ed. New York: Springer.

Lunde, A. & Timmermann, A. (2004). Duration dependence in stock prices: An analysis of bull and bear markets. *Journal of Business & Economic Statistics*, 22(3), 253-273.


Rabiner, L.R. (1989). A tutorial on hidden Markov models and selected applications in speech recognition. *Proceedings of the IEEE*, 77(2), pp. 257-286.

Yahoo Finance. (2026). *S&P 500 (^CSPC) Historical Data*. Tillgänglig på: <https://finance.yahoo.com/quote/%5EGSPC/history/> [Hämtad 10 april 2026].

Zucchini, W., MacDonald, I.L. & Langrock, R. (2016). *Hidden Markov Models for Time Series: An Introduction Using R*. 2nd ed. Boca Raton: Chapman and Hall/CRC.

Appendix/Bilagor

Figur 4. RAW-2 filtrerat estimerade marknadsregimer i diagram.



Figur 5. FET-3 filtrerat estimerade marknadsregimer i diagram.

